Rapport d'avancement — Projet 3 « Prévision de crues »

Ce rapport est mis à jour à chaque étape réalisée. L'état décrit ici correspond exactement à ce qui a été exécuté dans le dépôt.

1. Tâche 1 — Sources

Le fichier docs/sources.md documente les trois sources demandées : Hub'Eau pour les séries temporelles, Copernicus Sentinel-2 pour l'optique et Copernicus Sentinel-1 pour le radar. Pour chacune, il indique l'URL, le type de données, la fréquence, le format et l'accès requis.

2. Tâche 2.A — Collecte et préparation Hub'Eau

2.1 Ingestion

src/timeseries.py appelle l'API Hub'Eau Hydrométrie pour la station configurée dans `.env` ou `configs/params.yaml`. La pagination est gérée par `fetch_recent_observations`; `MAX_PAGES` est défini avant son usage et l'appel de collecte est effectué par `main`.

2.2 Nettoyage et transformation

Le script :

1. convertit les dates en datetime UTC ;
2. transforme les résultats numériques ;
3. supprime les doublons par station, date et grandeur ;
4. pivote les grandeurs H et Q en colonnes ;
5. convertit H de mm en m et Q de L/s en m³/s ;
6. rééchantillonne à 10 minutes ;
7. interpole uniquement les trous internes, dans une limite de trois pas ;
8. ajoute `H_m_missing` et `Q_m3_s_missing` pour tracer les valeurs manquantes ;
9. écrit `data/processed/timeseries_clean.csv`.

Cette étape a été exécutée avec succès : 16 111 observations brutes ont été téléchargées et 4 319 lignes régulières ont été produites.

3. Configuration et reproductibilité

configs/params.yaml externalise la station, la période, la pagination, la fréquence, la limite d'interpolation et les chemins.

requirements.txt contient l'environnement obtenu avec `pip freeze`. .gitignore ignore `.env`, `.venv/` et `data/`, afin de ne pas versionner les secrets ni les données lourdes.

4. Orchestration et qualité

src/pipeline.py permet de relancer automatiquement la
collecte et la préparation Hub'Eau en une commande :

```
.\.venv\Scripts\python.exe -m src.pipeline
```

Le pipeline valide le schéma, la fréquence, les doublons, les valeurs
négatives et produit un rapport JSON de qualité. Les tests de
tests/test_pipeline.py couvrent le schéma, le taux
de valeurs manquantes et le rejet des doublons.
La commande de test utilisée est :

```
.\.venv\Scripts\python.exe -m unittest discover -s tests -v
```

Résultat : 2 tests réussis.

5. Intégration continue

.github/workflows/ci.yml installe les dépendances,
compile les scripts et lance les tests à chaque push ou pull request. La CI
ne contacte pas les services externes et reste donc reproductible.

6. Partie satellite — en attente

Conformément à la demande, aucun compte Copernicus n'a été utilisé, aucun
téléchargement d'image n'a été lancé et `index.csv` n'a pas été créé.
src/satellite.py est uniquement un squelette : il lit
`CDSE_CLIENT_ID` et `CDSE_CLIENT_SECRET` depuis `.env`, puis contient un
`TODO` explicite pour la recherche, le téléchargement et la préparation
Sentinel-1/2. Il n'est pas appelé par le pipeline actuel.

7. Éléments restant à faire

- configurer un compte Copernicus et implémenter la collecte Sentinel-1/2 ;
- découper, redimensionner et normaliser les images ;
- créer l'alignement temporel dans `data/processed/index.csv` ;
- configurer DVC et un stockage distant pour les données ;
- ajouter ultérieurement fusion, entraînement, évaluation et suivi

d'expériences.
La partie Hub'Eau est terminée. La partie satellite et l'alignement sont en
attente.

8. Partie B — Fusion multimodale

L'étude bibliographique et le choix d'approche sont documentés dans
docs/partie_b_fusion.md. Le choix retenu est une
fusion intermédiaire légère par concaténation de représentations produites par
un encodeur temporel et un encodeur image, avec masque pour les images

manquantes. Ce choix est fondé sur les mesures actuelles : 4 320 pas de 10 minutes, une seule station, aucune image ni `index.csv` disponible à ce jour. La mise en œuvre du modèle sera faite après la collecte et l'alignement satellite.

9. Partie B.3 — Algorithme proposé

La proposition détaillée est dans docs/partie_b3_algorithme.md. Elle définit un GRU pour les fenêtres H/Q, un ResNet-18 pré-entraîné et d'abord figé pour les images, une projection commune en 64 dimensions, une concaténation avec masque de modalité manquante, une perte MAE et des baselines temporelle, image et fusion tardive. L'implémentation et l'évaluation attendent encore les images Copernicus et `index.csv`.

Partie B — Étude des approches de fusion de données

B.1 Étude bibliographique

La fusion multimodale consiste à exploiter plusieurs sources qui décrivent le

même phénomène. Ici, les modalités prévues sont :

- une série temporelle structurée : hauteur `H_m` et débit `Q_m3_s`, toutes les

10 minutes ;

- une image satellite autour de la station, prévue en 128 × 128 pixels ;
- une clé d'alignement fondée sur la date de l'image et le pas temporel

hydrométrique le plus proche.

Les trois niveaux classiques sont les suivants.

Comparaison des approches

Approche / réf.	Principe	Avantages	Limites	Conditions d'usage
Fusion précoce (Baltrušaitis et al., 2019)	Mettre les variables des modalités dans une représentation commune avant le modèle principal.	Simple, peu coûteuse, un seul modèle à entraîner.	Les dimensions, échelles et fréquences doivent être compatibles; risque de perdre la structure propre à chaque modalité.	Données déjà alignées et correctement normalisées.
Fusion tardive (Kiela et al., 2019)	Un modèle par modalité produit une prédiction; les sorties sont combinées par vote, moyenne pondérée ou stacking.	Fonctionne avec des modalités hétérogènes; une modalité peut manquer; interprétation facile par comparaison des modèles.	Les interactions fines entre modalités sont peu exploitées; plusieurs modèles à maintenir.	Peu de données, systèmes existants séparés ou modalités souvent absentes.
Intermédiaire — concaténation	Un encodeur par modalité produit un vecteur latent; les vecteurs sont concaténés puis envoyés à une tête commune.	Bon compromis entre simplicité et interactions; dimensions maîtrisées.	Le choix des encodeurs et de la taille des représentations influence le résultat.	Modalités alignées par échantillon et volume modéré.
Intermédiaire — somme ou produit pondérés	Additionner ou multiplier les représentations après projection dans un espace commun, avec poids appris ou fixés.	Peu de paramètres; somme robuste et produit capable de modéliser des interactions.	Le produit est sensible aux échelles; moins expressif qu'une attention.	Modalités déjà projetées dans le même espace.
GMU (Arevalo et al., 2017)	Une porte apprise règle la contribution de chaque modalité : une représentation est sélectionnée ou mélangée selon le contexte.	Gère le déséquilibre entre modalités et améliore la robustesse aux modalités peu fiables.	Ajoute des paramètres et demande assez de données pour apprendre la porte.	Une modalité peut être bruitée ou moins informative selon les exemples.
FiLM (Perez et al., 2018)	Une modalité produit des paramètres d'affinité et de biais qui modulent les activations d'une autre modalité.	Modulation conditionnelle efficace, plus légère qu'une fusion tensorielle.	Direction de la modulation à choisir; interactions moins symétriques.	Une modalité sert de contexte, par exemple la série conditionnant l'image.
TFN (Zadeh et al., 2017)	Produit tensoriel extérieur explicite des vecteurs unimodaux, avec terme de biais.	Modélise les interactions de tous les ordres.	Explosion du nombre de paramètres et du coût mémoire.	Beaucoup de données et représentations de petite dimension.
LMF (Liu et al., 2018)	Approxime le tenseur de TFN par des facteurs de faible rang.	Conserve des interactions riches avec moins de mémoire et de calcul.	Le rang doit être choisi; reste trop complexe pour un très petit jeu de données.	Ressources suffisantes et besoin avéré d'interactions d'ordre élevé.
Pooling bilinéaire MCB (Fukui et al., 2016)	Approxime le produit bilinéaire par un compact bilinear pooling aléatoire.	Réduit le coût du bilinéaire complet; utile pour image-texte.	Dimension de sortie parfois importante; moins naturel pour une courte série temporelle.	Vision-langage ou vecteurs de caractéristiques déjà extraits.
Pooling bilinéaire MFB (Yu et al., 2017)	Factorise et compacte les interactions bilinéaires avec un mécanisme multiplicatif.	Plus paramétrique et souvent plus performant que MCB.	Plus difficile à régler et à justifier sur un petit volume.	Tâches de question-réponse visuelle ou interactions riches.

Attention croisée / MulT (Tsai et al., 2019)	Les tokens d'une modalité interrogent ceux d'une autre par attention; les représentations sont fusionnées à plusieurs niveaux.	Alignement souple et interactions locales; traite des séquences de longueurs différentes.	Coût quadratique potentiel, besoin de données et de régularisation.	Séquences suffisamment longues, appariées et volume d'apprentissage important.
Transformer multimodal (Vaswani et al., 2017; Tsai et al., 2019)	Plusieurs blocs d'attention apprennent les interactions entre tokens de différentes modalités.	Très expressif et extensible à plusieurs modalités.	Beaucoup de paramètres, risque de surapprentissage et interprétation moins directe.	Grand corpus, pré-entraînement ou modèles pré-entraînés disponibles.
Goulot d'attention	Limiter l'échange intermodal à quelques tokens latents ou requêtes apprises.	Réduit le coût et force le modèle à sélectionner l'information utile.	Le goulot peut supprimer une information importante; réglage supplémentaire.	Nombre élevé de tokens ou ressources GPU limitées.
Alignement contrastif de type CLIP (Radford et al., 2021)	Rapprocher les représentations d'une paire correspondante et éloigner les paires non correspondantes.	Espace commun réutilisable; utile lorsque les paires sont nombreuses et fiables.	Demande beaucoup de paires négatives; l'objectif de similarité ne suffit pas toujours pour prévoir une crue.	Pré-entraînement multimodal ou grand nombre de paires image-série.
Fusion par graphes	Représenter les modalités, dates, bandes ou stations par des nœuds et leurs relations par des arêtes; un GNN agrège les voisins.	Représente explicitement les relations spatiales et temporelles.	Construction du graphe et interprétation plus complexes; peu utile avec une seule station.	Plusieurs stations, bassins ou relations spatiales connues.

Difficultés propres au multimodal

1. **Hétérogénéité.** Une série est un tableau ordonné et une image est une

grille de pixels. Elles ne peuvent pas être concaténées directement sans normalisation et encodeurs distincts.

1. **Alignement.** Une image n'est pas prise toutes les 10 minutes. Il faut

associer son horodatage au pas hydrométrique le plus proche et conserver la distance temporelle. Une association trop éloignée peut créer un faux lien.

1. **Modalité manquante.** Une image peut ne pas être disponible à cause des

nuages, du passage du satellite ou de l'authentification. Le modèle doit recevoir un masque de présence et pouvoir fonctionner avec la série seule.

1. **Déséquilibre.** La série est disponible à chaque pas alors que les images

sont rares. Sans pondération, la branche temporelle peut dominer la perte.

1. **Coût de calcul.** Les transformers, TFN et pooling bilinéaires ont un coût

disproportionné par rapport à 4 320 lignes et une seule station.

1. **Interprétabilité.** Pour une alerte de crue, il faut pouvoir distinguer

l'effet du signal H/Q de l'apport de l'image; les poids de fusion et des ablations par modalité sont donc importants.

B.2 Choix pour ce projet

Données mesurées

La préparation actuelle fournit 4 320 lignes sur 30 jours, à une fréquence régulière de 10 minutes. Les colonnes hydrométriques sont `H_m`, `Q_m3_s` et leurs indicateurs de manque. Il n'y a actuellement aucune image préparée et aucun `index.csv`, car l'accès Copernicus n'est pas disponible.
Le jeu est donc petit pour entraîner un modèle multimodal de bout en bout.
Il contient aussi une seule station : une fusion par graphe n'aurait pas de

relation spatiale à apprendre. Enfin, la fréquence de la série est beaucoup plus fine que la revisite satellite, ce qui impose un alignement explicite et un masque de disponibilité.

Approche retenue

L'approche retenue est une **fusion intermédiaire légère par concaténation après encodeurs séparés**, avec un** masque de modalité manquante** :

1. un petit encodeur 1D (ou GRU) résume une fenêtre de H/Q ;
2. un encodeur CNN pré-entraîné et gelé résume l'image 128 × 128 ;
3. les deux vecteurs sont projetés vers une dimension commune ;
4. les vecteurs, le masque image et la distance temporelle sont concaténés ;
5. une petite tête dense prédit la cible de crue.

Cette décision s'appuie sur les observations du projet :

Critère	Constat	Conséquence
Nature des modalités	Tableau H/Q contre image 128 × 128.	Encodeur propre à chaque modalité, pas de concaténation brute.
Alignement	Pas de date d'image disponible aujourd'hui; la série est à 10 minutes et le satellite est beaucoup plus rare.	`index.csv`, date la plus proche, écart temporel et masque sont nécessaires.
Interactions	L'image peut apporter le contexte de l'occupation du sol, mais H/Q reste le signal direct.	Concaténation tardive des représentations, sans TFN au départ.
Modalités manquantes	Images absentes en attendant Copernicus et potentiellement absentes à certaines dates.	Branche image masquée et entraînement avec cas série seule.
Volume	4 320 lignes, une station, images non disponibles.	Encodeur image gelé; pas de transformer entraîné de bout en bout.
Calcul	Pas de GPU requis pour un premier modèle simple.	CNN pré-entraîné + petite tête, plutôt que MulT ou TFN.
Interprétabilité	Décision de crue à expliquer.	Comparaison série seule / image seule / fusion et ablation du masque.

Ordre de mise en œuvre

1. Constituer `index.csv` après récupération des images et mesurer l'écart entre chaque image et le pas H/Q associé.
1. Établir une baseline série seule avec un modèle 1D ou GRU.
2. Ajouter un CNN gelé et la concaténation intermédiaire.
3. Ajouter le masque d'image et tester les dates sans image.
4. Comparer à une fusion tardive (deux modèles et moyenne pondérée).
5. N'envisager GMU ou FiLM que si le volume d'images justifie une porte ou une modulation apprises.

Les transformers multimodaux, TFN/LMF, MCB/MFB, CLIP et les graphes sont pertinents dans d'autres régimes de données, mais ils ne sont pas le premier choix justifié pour ce jeu court, monostation et actuellement unimodal.

Références

- Baltrušaitis, Ahuja, Morency, *Multimodal Machine Learning: A Survey and Taxonomy*, IEEE TPAMI, 2019. https://doi.org/10.1109/TPAMI.2018.2798607

- Arevalo et al., *Gated Multimodal Units for Information Fusion*, ICLR

Workshop, 2017. https://arxiv.org/abs/1702.01992

- Perez et al., *FiLM: Visual Reasoning with a General Conditioning Layer*,

AAAI, 2018. https://arxiv.org/abs/1709.07871

- Zadeh et al., *Tensor Fusion Network for Multimodal Sentiment Analysis*,

EMNLP, 2017. https://aclanthology.org/D17-1115/

- Liu et al., *Efficient Low-rank Multimodal Fusion with Modality-Specific

Factors*, ACL, 2018. https://aclanthology.org/P18-1209/

- Fukui et al., *Multimodal Compact Bilinear Pooling for Visual Question

Answering and Visual Grounding*, EMNLP, 2016.

https://aclanthology.org/D16-1044/

- Yu et al., *Multi-modal Factorized Bilinear Pooling with Co-attention

Learning for Visual Question Answering*, ICCV, 2017.

https://openaccess.thecvf.com/content_ICCV_2017/html/Yu_Multi-Modal_Factorized_Bilinear_ICCV_2017_paper.html

- Tsai et al., *Multimodal Transformer for Unaligned Multimodal Language

Sequences*, ACL, 2019. https://aclanthology.org/P19-1656/

- Radford et al., *Learning Transferable Visual Models From Natural Language

Supervision*, ICML, 2021. https://arxiv.org/abs/2103.00020

- Vaswani et al., *Attention Is All You Need*, NeurIPS, 2017.

https://arxiv.org/abs/1706.03762

- Songtao et al., *Multimodal Alignment and Fusion: A Survey*, IJCV, 2026.

https://doi.org/10.1007/s11263-025-02667-1

B.3 Proposition des algorithmes de fusion

1. Architecture proposée

Le modèle utilise une fenêtre temporelle de 36 pas, soit 6 heures de mesures H/Q. Chaque exemple contient donc :

- `x_t` : un tableau de dimension `(36, 2)` avec `H_m` et `Q_m3_s` ;
- `x_i` : une image satellite RGB de dimension `(3, 128, 128)` ;
- `m_i` : un masque égal à 1 si l'image est disponible et à 0 sinon ;
- `delta_t` : l'écart en minutes entre la date de l'image et la date de la cible.

L'encodeur temporel est un GRU bidirectionnel à une couche, avec 32 unités dans chaque direction. Sa sortie est donc un vecteur de 64 valeurs. Une projection linéaire `64 -> 64` produit `h_t`.

L'encodeur image est un ResNet-18 pré-entraîné sur ImageNet. Sa dernière couche de classification est retirée. Le réseau est d'abord figé afin de limiter le surapprentissage sur le petit jeu actuel, puis une phase optionnelle pourra dégeler le dernier bloc si suffisamment d'images sont disponibles. La sortie 512-dimensionnelle est projetée par une couche `512 -> 64` pour produire `h_i`.

Le module de fusion est une concaténation enrichie :

```
z = [h_t ; m_i * h_i + (1 - m_i) * e_abs ; delta_t / 360]
```

où `e_abs` est un vecteur appris de 64 valeurs utilisé lorsque l'image manque.

Le vecteur `z` a 129 dimensions. Une tête MLP `129 -> 64 -> 1` prédit le débit à l'horizon choisi. Pour prévoir plusieurs horizons, la dernière couche produira un vecteur de sorties plutôt qu'une seule valeur.

2. Module de fusion et passe avant

Pour un batch de taille `B`, on note :

```
h_t = Proj_t(GRU(x_t))              h_t ∈ R^(B×64)h_i = Proj_i(ResNet18(x_i))         h_i ∈ R^(B×64)u_i
= m_i h_i + (1 - m_i) e_abs     u_i ∈ R^(B×64)z   = [h_t, u_i, delta_t / 360]     z   ∈ R^(B×129)ŷ   =
MLP(z)                          ŷ   ∈ R^B
```

Les variables H et Q sont normalisées avec les statistiques du seul ensemble d'entraînement. L'image est normalisée avec les statistiques ImageNet si ResNet-18 est utilisé. Les dates et les valeurs futures ne sont jamais utilisées pour construire une fenêtre d'entrée.

Pseudo-algorithme de la passe avant

```
Entrées : x_t, x_i, m_i, delta_t, cible yParamètres : E_t, Proj_t, E_i, Proj_i, e_abs, MLP1. h_t ←
Proj_t(E_t(x_t))2. si m_i = 1 alors       h_i ← Proj_i(E_i(x_i))   sinon       h_i ← e_abs3. u_i ← h_i
avec la valeur masquée par m_i4. z ← concaténer(h_t, u_i, delta_t / 360)5. ŷ ← MLP(z)6. retourner ŷ
```

Le calcul de l'image peut être évité pour les exemples où `m_i = 0`. Les représentations image calculées pour les dates valides sont mises en cache après extraction, avec l'identifiant du produit et la version du modèle.

3. Entraînement et fonction de perte

La perte principale est une erreur absolue moyenne, adaptée aux pics et moins sensible que l'erreur quadratique aux valeurs extrêmes :

```
L_task = mean(|ŷ - y|)
```

Pour empêcher la branche image d'être ignorée, une perte auxiliaire temporelle est ajoutée pendant les premières expériences. Elle utilise une petite tête sur `h_t` :

```
L_time = mean(|H_time(h_t) - y|)L = L_task + 0.2 * L_time
```

La perte auxiliaire est retirée si elle dégrade la validation. Une perte contrastive n'est pas retenue au départ : le nombre de paires image-série sera faible et l'alignement ne sera fiable qu'après la création de `index.csv`.
L'optimiseur proposé est AdamW, taux initial `1e-3` pour les projections et la tête, poids décroissant `1e-4`, batch de 32 lorsque la mémoire le permet, et arrêt anticipé sur la perte de validation. Le ResNet reste gelé pendant cette phase.

Pseudo-algorithme d'entraînement

```
Pour chaque batch (x_t, x_i, m_i, delta_t, y) :1. ŷ, h_t ← passe_avant(x_t, x_i, m_i, delta_t)2. L_task ← MAE(ŷ, y)3. L_time ← MAE(H_time(h_t), y)4. L ← L_task + 0.2 * L_time5. remettre les gradients à zéro6. rétropropager L7. mettre à jour les paramètres entraînables avec AdamW8. calculer les métriques sur l'ensemble de validation9. conserver le meilleur modèle et arrêter si la validation stagne
```

4. Modalités manquantes et déséquilibre

Une image absente est représentée explicitement par `m_i = 0`, le vecteur `e_abs` et `delta_t = 0`. Le modèle peut donc produire une prévision à partir de la série seule. Pendant l'entraînement, un modality dropout met artificiellement `m_i` à zéro pour 20 % des exemples possédant une image.
Cette méthode évite que le modèle devienne inutilisable lorsque les passages du satellite sont espacés ou que les nuages masquent la zone.
Le déséquilibre est traité par trois mesures simples :

1. normalisation séparée des H/Q et des pixels ;
2. projection des deux encodeurs dans la même dimension 64 ;
3. comparaison systématique avec les modèles unimodaux.

Une porte GMU ou une pondération apprise ne sera ajoutée que si les expériences montrent qu'une modalité domine durablement. Il vaut mieux ne pas ajouter ce paramètre avant d'avoir assez d'images pour l'estimer.

5. Baselines

Les comparaisons minimales sont :

1. **Baseline persistance** : la dernière valeur connue de Q est reprise pour

l'horizon de prévision.

1. **Modèle temporel seul** : le GRU sur H/Q, sans image.
2. **Modèle image seul** : ResNet-18 gelé suivi d'une tête MLP, pour vérifier

si l'image contient un signal prédictif.

1. **Fusion tardive** : moyenne pondérée des prédictions des modèles temporel

et image, avec le poids choisi sur la validation.

1. **Modèle retenu** : concaténation intermédiaire avec masque.

Le modèle fusionné ne sera considéré utile que s'il améliore le GRU seul et la persistance sur un jeu de test gardé à part.

6. Évaluation et ablations

Le découpage est chronologique : les premières dates servent à l'entraînement, la période suivante à la validation et la dernière période au test. Il ne faut pas mélanger des fenêtres qui se recouvrent entre ces ensembles, afin d'éviter une fuite temporelle.

Les métriques sont :

- MAE en m³/s ;
- RMSE en m³/s ;
- coefficient de détermination R^2 ;
- erreur sur les pics, calculée sur les valeurs du dernier décile de Q ;
- rappel et précision d'un événement de crue défini par un seuil fixé sur

l'entraînement.

Les ablations prévues sont :

- série seule contre fusion ;
- image seule contre fusion ;
- image remplacée par `e_abs` ;
- retrait de `delta_t` ;
- retrait de la perte auxiliaire ;
- concaténation contre fusion tardive ;
- ResNet gelé contre dernier bloc affiné ;
- taux de modality dropout 0 %, 20 % et 50 %.

Toutes les métriques seront calculées sur le même test et avec la même graine.

7. Intégration dans le pipeline

Les étapes de la Partie A à ajouter ou modifier sont :

1. **Alignement** : créer `data/processed/index.csv` après téléchargement,

avec `image`, `date_utc`, `H_m`, `Q_m3_s`, `delta_minutes` et `image_present`.

1. **Fenêtrage** : construire les fenêtres de 36 pas sans utiliser de mesure

postérieure à la cible.

1. **Extraction image** : appliquer la normalisation ResNet et enregistrer les vecteurs 64-dimensionnels dans un cache versionné par produit.
1. **Validation** : vérifier les dimensions 128 × 128, les dates, les clés d'alignement et le taux de modalités manquantes.
1. **Entraînement** : ajouter un module `src/fusion/` contenant le modèle, la perte, les baselines et le découpage chronologique.
1. **Évaluation** : écrire les métriques et les résultats d'ablation dans `data/processed/metrics.json`.

Tant que les images et l'index ne sont pas disponibles, seule la baseline temporelle peut être exécutée. Le modèle proposé est donc une spécification prête à implémenter, et non un entraînement déjà réalisé.